

PRESENTACIÓN PROYECTO

TESIS DE DOCTORADO: ☐

TESIS DE MAESTRÍA: ☒

1. Proponente: Brayan Steven Peña Delgadillo
2. Identificación: 1014268102
3. Programa: Maestría en Ingeniería de Sistemas y Computación
4. Director propuesto: Fabio Augusto González
Departamento del director: Departamento de Ingeniería de Sistemas e Industrial
Institución del director: Universidad Nacional de Colombia -Sede Bogotá
5. Codirector propuesto (opcional): N/A
6. Grupo de investigación (opcional): MindLab
7. Título: Análisis Comparativo del Desempeño entre Kernel Density Matrix y Probabilistic Neural Circuits.
8. Línea de investigación: Sistemas Inteligentes.
9. Introducción

El aprendizaje profundo probabilístico (Probabilistic Deep Learning) ha evolucionado como una alternativa fundamental para el modelado de distribuciones complejas y la estimación de incertidumbre; entre múltiples enfoques existentes, se destacan dos líneas de desarrollo, los modelos basados en circuitos probabilísticos tractables y los enfoques cuántico-inspirados que emplean matrices de densidad. La primera línea está representada por los Probabilistic Neural Circuits (PNCs) [1], los cuales permiten realizar inferencia eficiente debido a que mantiene un equilibrio entre eficiencia computacional e interpretabilidad estructural.

De manera paralela, los enfoques cuántico-inspirados incorporan principios matemáticos provenientes de la física, exactamente de la mecánica cuántica para representar distribuciones mediante matrices de densidad, su más reciente avance es la propuesta de las Kernel Density Matrices (KDMs) [2], un marco general que unifica y extiende otros algoritmos cuánticos-inspirados para abordar tareas de clasificación, regresión y estimación de densidades mediante el uso de operadores, kernels y aprendizaje profundo.

A pesar del progreso alcanzado en ambos paradigmas, la literatura actual carece de estudios comparativos rigurosos que evalúen su desempeño bajo condiciones experimentales equivalentes. Esta ausencia dificulta comprender hasta qué punto los KDMs pueden igualar o superar la eficacia de los PNCs, especialmente en escenarios de alta dimensionalidad donde la eficiencia, la capacidad de representación y la calibración de incertidumbre son factores determinantes.

Por lo tanto, se propone una evaluación comparativa estandarizada de ambos modelos en escenarios unificados, que permita analizar el desempeño de los Kernel Density Matrix en problemas y conjuntos de datos donde los Probabilistic Neural Circuits ya han sido bastante estudiados y han demostrado muy buenos resultados.

10. Antecedentes:

En la última década, el Deep Learning ha revolucionado la inteligencia artificial, permitiendo a los modelos aprender de representaciones jerárquicas de los datos de manera automática [3]. Una extensión de esto es el aprendizaje profundo probabilístico, que combina el poder representacional de las redes neuronales con el rigor estadístico de los modelos probabilísticos, para capturar la incertidumbre y mejorar la interpretabilidad de las predicciones [4].

Dentro de este campo han evolucionado dos líneas de desarrollo importantes. La primera corresponde a los modelos estructurados basados en Circuitos Probabilísticos (PCs) tractables [5], que garantizan inferencia exacta y eficiente mediante representaciones jerárquicas de suma y producto. La segunda está compuesta por modelos cuántico-inspirados basados en matrices de densidad, que toman elementos formales de la mecánica cuántica para representar distribuciones probabilísticas [2]. Aunque provienen de enfoques distintos, ambos buscan modelar distribuciones de alta dimensionalidad de manera estable, interpretable y con una calibración de incertidumbre superior a la de los métodos profundos tradicionales.

10.1 Definición y Caracterización de los Circuitos Probabilísticos

Un Circuito Probabilístico (PC) es un grafo computacional acíclico y dirigido (DAG) que codifica una función de densidad de probabilidad o una función de masa de probabilidad sobre un conjunto de variables aleatorias [5]. A diferencia de los modelos gráficos tradicionales como las Redes Bayesianas, que requieren algoritmos de inferencia complejos o aproximados, los PCs están diseñados estructuralmente para ser tratables, esto significa que las probabilidades marginales o condicionales se calculan mediante una sola pasada de propagación (feed-forward) en el grafo [5][6]. La arquitectura de estos circuitos se compone de nodos hoja, que representan distribuciones univariadas simples (como distribuciones Bernoulli o Gaussianas) [5], y nodos internos de suma y producto [7]. Los nodos de suma modelan mezclas probabilísticas, permitiendo capturar la incertidumbre y la multimodalidad de los datos [5][7], mientras que los nodos de producto codifican factorizaciones de independencia condicional [5][6].

Para garantizar tanto la corrección matemática como la eficiencia inferencial, los PCs deben cumplir con propiedades estructurales estrictas:

- La Descomponibilidad (Decomposability) exige que los hijos de un nodo producto operen sobre conjuntos de variables disjuntos. Esta propiedad permite que la integración global se descomponga en productos de integrales locales, facilitando el cálculo exacto de marginales [5][7].
- La Suavidad (Smoothness), posteriormente denominada Completitud (Completeness)[7], requiere que todos los hijos de un nodo suma cubran exactamente el mismo conjunto de variables. Esto garantiza que la suma represente una distribución de probabilidad válida y normalizada [5][6].
- El Determinismo (Determinism) es una propiedad más restrictiva que estipula que para cualquier entrada completa dada, a lo sumo uno de los hijos de un nodo suma puede tener una salida distinta de cero, lo cual es crucial para ciertas tareas de maximización [6][8].

10.2 Evolución de los Circuitos Probabilísticos Tractables.

La historia de los PCs es una búsqueda constante por equilibrar la expresividad (capacidad de modelar distribuciones complejas) y la tractabilidad (capacidad de responder consultas probabilísticas de forma exacta y eficiente). A principios del siglo XXI, fundamentados en el desarrollo de los Network Polynomials, estructuras algebraicas para evaluar eficientemente probabilidades en modelos gráficos, surgieron los Circuitos Aritméticos (ACs) [6]. Estos modelos sentaron las bases de la tractabilidad algorítmica al compilar la distribución de probabilidad en DAG de sumas y productos y garantizaban inferencia exacta y determinista cumpliendo las propiedades de descomponibilidad, suavidad y determinismo [6]. Su aplicación se concentraba principalmente en variables discretas y dominios lógicos, superando a las redes bayesianas tradicionales en conectividad, aunque dependían de la traducción de conocimiento experto previo en lugar del aprendizaje automático [5][6].

Este paradigma cambió en 2011 con la introducción de las Sum-Product Networks (SPNs) [7], las cuales permitieron el aprendizaje estructural profundo directamente desde los datos. Las SPNs demostraron su capacidad en visión por computadora (en datasets como Caltech-101 y Olivetti Faces), relajando el determinismo para mejorar la generalización en inferencia de evidencia parcial, pero manteniendo la descomponibilidad y completitud para asegurar la tractabilidad [7][8]. Para abordar las limitaciones en la representación de dependencias condicionales, surgieron las Sum-Product-Quotient Networks (SPQNs) [9], que incorporan nodos de cociente para el cálculo directo de $P(A|B)$, para lograr una expresividad exponencialmente superior a las SPNs estándar, permitiendo modelar distribuciones complejas de forma compacta, algo crucial para datos con alta dependencia combinatoria [9].

Posteriormente, las Einsum Networks [10] optimizaron la implementación mediante operaciones tensoriales monolíticas en GPUs, permitiendo entrenar modelos profundos

en datasets masivos como SVHN, CelebA y MNIST. Las EiNets demostraron que la inferencia exacta podía competir en verosimilitud con modelos intratables (VAEs) en datos visuales realistas [10].

Finalmente, la evolución más reciente apunta a la hibridación. Zuidberg Dos Martires (2024) propuso los Probabilistic Neural Circuits (PNCs) [1], que integran la estructura de los PCs con mecanismos diferenciables propios del aprendizaje profundo, incorporando capas paramétricas entrenables mediante gradientes. Paralelamente, los Neural Probabilistic Circuits (NPCs) [11] se enfocan en el razonamiento lógico e interpretable sobre atributos semánticos (evaluados en CUB-200-2011 y CelebA), permitiendo clasificaciones explicables y corregibles mediante reglas lógicas, diferenciándose así de la generación pura de píxeles [11].

Cuadro 1: Comparación de los modelos basado en los circuitos probabilísticos

Referencia	Modelo	Impacto	Enfoque	Propiedades	Tipo de Datos y Datasets
A. Darwiche (2003)	Arithmetic Circuits (ACs)	Sentaron las bases de la tractabilidad probabilística mediante compilación.	Inferencia exacta y diagnósticos en sistemas expertos.	Determinismo, Descomponibilidad, Suavidad.	Datos Discretos / Lógicos. (Alarm, Insurance, Hailfinder).
Poon & Domingos (2011)	Sum-Product Networks (SPNs)	Primer modelo profundo tratable aprendido desde cero; superó el estado del arte en visión.	Modelado generativo profundo y manejo de datos faltantes.	Descomponibilidad, Completitud. (Relaja el determinismo).	Imágenes y Texto. (Caltech-101, Olivetti Faces, 20 Newsgroups).
Sharir & Shashua (2018)	Sum-Product-Quotient Networks (SPQNs)	Aumento exponencial en la capacidad expresiva respecto a las SPNs.	Modelado explícito de probabilidad condicional mediante cocientes.	Descomponibilidad Condicional, Suavidad Condicional. (Nodos Cociente).	Datos de Alta Complejidad Combinatoria. Principalmente teóricos / sintéticos
Peharz, et al. (2020)	Einsum Networks (EiNets)	Escalabilidad masiva a hardware moderno (GPUs) y Big Data.	Entrenamiento rápido de modelos profundos mediante operaciones tensoriales.	Descomponibilidad, Suavidad. (Implementación monolítica).	Imágenes Realistas a Gran Escala. (SVHN, CelebA, MNIST)



Zuidberg Dos Martires (2024)	Probabilistic Neural Circuits (PNCs)	Hibridación efectiva con Deep Learning (gradientes + estructura).	Aproximación de funciones complejas (mezclas profundas de redes bayesianas).	Estructura tratable + Capas neuronales paramétricas.	Imágenes (MNIST, Fashion- MNIST, EMNIST).
ChenW, et al. (2025)	Neural Probabilistic Circuits (NPCs)	Transición de modelos de caja negra a modelos lógicos explicables (XAI).	Clasificación interpretable, razonamiento lógico y corrección humana.	Composición Lógica, Interpretabilidad.	Imágenes con Atributos Semánticos. (CUB-200-, CelebA)

10.2 Evolución hacia los Kernel Density Matrices (KDMs)

De forma paralela a los circuitos, se ha desarrollado un enfoque basado en matrices de densidad, estructuras fundamentales de la mecánica cuántica empleadas para describir estados mixtos.

Los primeros avances en esta dirección fueron los modelos de Quantum Measurement Classification (QMC) [12], donde las predicciones se obtienen mediante operadores proyectores siguiendo la regla de Born. Este marco fue expandido posteriormente con modelos que incorporan técnicas kernelizadas y construcciones basadas en matrices mixtas [13]. Entre ellos destaca el Density Matrix Kernel Density Estimation (DMKDE), un modelo no paramétrico que extiende la estimación de densidad tradicional al representar distribuciones de probabilidad como matrices de densidad [13], así como extensiones del QMC para regresión ordinal o continua.

La propuesta más reciente en esta línea son los Kernel Density Matrices (KDMs) [2], que introducen un marco unificado combinando inferencia cuántico-inspirada, métodos de kernel y aprendizaje profundo para construir matrices de densidad conjuntas. Esta formulación permite abordar tareas de clasificación, regresión, estimación de densidades y generación condicional bajo un mismo formalismo. En una dirección complementaria, el proyecto DEMANDE [14] desarrolla métodos de Density Matrix Neural Density Estimation, donde redes neuronales profundas aprenden directamente representaciones matriciales que satisfacen las restricciones matemáticas de la mecánica cuántica.

11. Planteamiento del problema:

El paradigma de los PNCs ha sido estudiado con mayor profundidad y cuenta con resultados consolidados en diversos problemas. En contraste, se desconoce si los KDMs, siendo un enfoque más reciente inspirado en la mecánica cuántica, pueden igualar o superar el desempeño de los PNCs en problemas establecidos donde estos últimos han demostrado efectividad.

En la actualidad no se ha caracterizado de forma precisa cómo se comportan ambos enfoques bajo las mismas condiciones experimentales, ni existen métricas estandarizadas que permitan cuantificar el equilibrio entre eficiencia y poder representacional. Por tanto, el problema central de esta investigación se formula como: ¿Cómo se desempeña el algoritmo Kernel Density Matrix (KDM) en comparación con los Probabilistic Neural Circuits (PNCs) en tareas de modelado probabilístico sobre datos de alta dimensionalidad y estructuras de correlación complejas?

12. Justificación:

La necesidad de comprender la relación entre tractabilidad y expresividad en el modelado probabilístico profundo convierte la comparación entre KDMs y PNCs en un desafío tanto teórico como aplicado. Mientras los PNCs representan arquitecturas altamente eficientes y tractables [1], los KDMs introducen un formalismo inspirado en la física cuántica que permite representar distribuciones complejas mediante matrices de densidad y realizar inferencias reversibles [2]. A pesar de su potencial, ningún estudio previo ha comparado rigurosamente ambos paradigmas bajo condiciones experimentales controladas.

Esta ausencia de análisis sistemático genera una falta de comprensión sobre el equilibrio tractabilidad–expresividad. Además, impide contar con guías basadas en evidencia para seleccionar el enfoque más adecuado en tareas reales. La falta de un estudio comparativo limita la comprensión de los límites teóricos y prácticos de cada paradigma, dificulta la toma de decisiones informadas en aplicaciones reales y restringe la adopción de modelos cuántico-inspirados debido a la ausencia de evidencia sólida que respalde su desempeño relativo frente a arquitecturas probabilísticas consolidadas como los PNCs.

13. Objetivo general y objetivos específicos

13.1 Objetivos General:

Evaluar el desempeño del algoritmo Kernel Density Matrix (KDM) en comparación con los Probabilistic Neural Circuits (PNCs) para el modelado probabilístico de datos complejos.

12.2 Objetivos específicos:

- Identificar problemas y conjuntos de datos representativos que permitan una comparación adecuada entre ambos modelos.
- Preparar los datos y las estructuras de entrada necesarias para la implementación de PNCs y KDMs, garantizando compatibilidad con sus requerimientos experimentales.
- Implementar ambos modelos bajo condiciones experimentales controladas y reproducibles.
- Comparar el desempeño de los modelos mediante métricas estandarizadas y criterios cuantitativos

14. Diseño de la investigación:

La metodología propuesta combina el estándar CRISP-DM (Cross-Industry Standard Process for Data Mining) con las fases clásicas del diseño de investigación, está estructurada en seis fases orientadas hacia el desarrollo de los objetivos.

- Fase 1: Comprensión del problema (Objetivo 1)
 - Se definen los criterios para seleccionar los problemas y conjuntos de datos donde ambos modelos (PNCs y KDMs) pueden compararse de manera justa. Se revisa literatura y limitaciones técnicas.

Entregables: Documento de caracterización del problema y Matriz de Selección de Datasets.

- Fase 2: Comprensión y análisis de datos (Objetivo 1)
 - Se examina detalladamente las características de cada conjunto de datos, su estructura, calidad, distribución y pertinencia para los modelos, mediante estadísticas, visualizaciones y detección de inconsistencias. Se identifican requisitos, limitaciones, patrones iniciales y posibles retos de preparación.

Entregables: Análisis exploratorio de datos (EDA) con visualizaciones, estadísticas y conclusiones sobre la adecuación de los datos.

- Fase 3: Preparación y preprocesamiento de datos (Objetivo 2)
 - Se organiza y transforma los datos para hacerlos compatibles con ambos modelos. Incluye limpieza, normalización, generación de particiones, y preparación de las estructuras necesarias para entrenar PNCs y diseñar la implementación de KDMs.

Entregables: Pipeline de preprocesamiento documentado, listo para utilizarse directamente en los experimentos, módulo de transformación específica y diccionario de datos procesados.

- Fase 4: Modelado (Objetivo 3)
 - Se implementan ambos modelos (PNCs y KDMs) bajo condiciones experimentales controladas. Se configuran hiperparámetros, arquitecturas y protocolos de entrenamiento.

Entregables: Implementaciones funcionales de PNCs y KDMs, con scripts ejecutables y configuraciones reproducibles.

- Fase 5: Evaluación (Objetivo 4)
 - Se analizan los resultados obtenidos por ambos modelos utilizando métricas estandarizadas. Se evalúa desempeño, estabilidad, generalización, incertidumbre, costo computacional y eficiencia. Se comparan cuantitativamente los modelos y se interpretan los hallazgos.

Entregables: Informe comparativo de desempeño, con tablas, métricas, gráficos y análisis estadístico.

- Fase 6: Despliegue y documentación
 - Se integran todos los resultados, conclusiones, implicaciones y limitaciones del estudio. Preparación del documento final, anexos técnicos y repositorio reproducible.

Entregables: Documento final de Tesis, anexos técnicos y repositorio completo.

15. Actividades a desarrollar:

- Fase 1 Comprensión del problema.
 - Revisar literatura especializada sobre PNCs, KDMs y sus áreas de aplicación.
 - Definir los criterios de selección de problemas: complejidad, tipo de tarea, dimensionalidad y disponibilidad de datos.
 - Elaborar una matriz comparativa para analizar la pertinencia de diferentes problemas frente a ambos modelos.
 - Seleccionar y justificar los datasets adecuados.
- Fase 2 Comprensión y análisis de datos.
 - Realizar análisis exploratorio completo de cada dataset (estadísticas, visualizaciones, correlaciones, patrones).
 - Identificar inconsistencias, valores faltantes, ruido y posibles problemas de distribución.
 - Determinar qué características del dataset afectan directamente la aplicabilidad de PNCs y KDMs.
 - Documentar requerimientos de entrada exigidos por ambos modelos (dimensionalidad, tipos de datos, estructuras).
 - Establecer criterios preliminares de preprocesamiento y transformación.
- Fase 3 Preparación y preprocesamiento de datos.
 - Realizar limpieza y depuración: imputación, normalización, estandarización o reducción de ruido.



- Construir las particiones de entrenamiento, validación y prueba bajo un esquema reproducible.
- Generar las representaciones adecuadas para cada modelo.
- Diseñar el pipeline experimental que se utilizará durante el modelado.
- Validar que los datos preprocesados cumplen los requisitos técnicos y formales de ambos modelos.
- Fase 4 Modelado.
 - Diseñar e implementar el modelo Kernel Density Matrices (KDMs) adaptado a los problemas seleccionados.
 - Implementar la arquitectura de Probabilistic Neural Circuits (PNCs) siguiendo su formulación estructural.
 - o Configurar hiperparámetros, mecanismos de optimización y criterios de entrenamiento para ambos modelos.
 - o Ejecutar entrenamientos bajo condiciones controladas, registrando resultados y parámetros.
- Fase 5 Evaluación.
 - Evaluar ambos modelos usando métricas estandarizadas (precisión, error, log-likelihood, calibración).
 - Analizar estabilidad, robustez, generalización y comportamiento ante incertidumbre.
 - Realizar comparaciones cuantitativas mediante pruebas estadísticas cuando corresponda.
 - Generar visualizaciones que contrasten los resultados obtenidos por los dos enfoques.
- Fase 6 Despliegue y documentación final.
 - Elaborar anexos técnicos con configuraciones, código y decisiones metodológicas.



- Preparar un repositorio completo y reproducible (scripts, datos, manual de ejecución).
- Redactar el documento final formal con los resultados y la discusión final, limitaciones e implicaciones del estudio.

16. Cronograma:

El cronograma se organiza en 28 semanas, distribuyendo las actividades correspondientes a las seis fases metodológicas. Además, se emplea un esquema de colores para identificar claramente las acciones asociadas a cada uno de los cuatro objetivos específicos.

Cuadro 2. Cronograma

		SEMANA																											
Fase	Actividad	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28
1	Revisión de literatura	x	x	x	x																								
1	Definir criterios de selección		x	x	x																								
1	Matriz comparativa			x	x																								
1	Selección de datasets				x																								
2	EDA completo					x	x	x	x	x																			
2	Identificar inconsistencias					x	x	x	x	x																			
2	Impacto en PNCs y KDMs						x	x	x	x																			
2	Documentar requisitos							x	x	x																			
2	Criterios de preprocesamiento								x	x																			
3	Limpieza y depuración										x	x	x	x	x														
3	Particiones reproducibles										x	x	x	x	x														
3	Representaciones adecuadas											x	x	x	x														
3	Diseño del pipeline												x	x	x														
3	Validación técnica													x	x														
4	Implementación KDM															x	x												
4	Implementación PNC																x	x											
4	Configurar hiperparámetros																		x	x									
4	Entrenamientos controlados																				x	x							

- [2] González, F., Ramos-Pollán, R., & Gallego, J. (2025). Kernel density matrices for probabilistic deep learning. Quantum Machine Intelligence, 7, 94.
<https://doi.org/10.1007/s42484-025-00299-9>
- [3] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- [4] Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). Mathematics for Machine Learning. Cambridge University Press. <https://mml-book.github.io>
- [5] Choi, Y., Vergari, A., & Van den Broeck, G. (2020). Probabilistic Circuits: A Unifying Framework for Tractable Probabilistic Models. UCLA StarAI Lab.
<https://starai.cs.ucla.edu/papers/ProbCirc20.pdf>
- [6] A. Darwiche. (2003). A differential approach to inference in Bayesian networks. Journal of the ACM <https://doi.org/10.1145/765568.765570>
- [7] Poon, H., & Domingos, P. (2011). Sum-product networks: A new deep architecture. In Proceedings of the IEEE International Conference on Computer Vision Workshops (ICCVW). <https://doi.org/10.1109/ICCVW.2011.6130310>
- [8] Choi, A., & Darwiche, A. (2017). On Relaxing Determinism in Arithmetic Circuits. En International Conference on Machine Learning (ICML).
<https://doi.org/10.48550/arXiv.1708.06846>
- [9] Sharir, O., & Shashua, A. (2018). Sum-Product-Quotient Networks. En Proceedings of the 21st International Conference on Artificial Intelligence and Statistics (AISTATS).
<https://proceedings.mlr.press/v84/sharir18a.html>.

[10] Peharz, R., Gens, R., Domingos, P., & Pernkopf, F. (2020). Einsum networks: Fast and scalable learning of tractable probabilistic circuits. In Proceedings of the 37th International Conference on Machine Learning (ICML 2020) (pp. 7563–7574). PMLR. <https://proceedings.mlr.press/v119/peharz20a.html>

[11] Chen, W., et al. (2025). Neural Probabilistic Circuits: Enabling Compositional and Interpretable Predictions through Logical Reasoning. <https://doi.org/10.48550/arXiv.2501.07021> .

[12] González, F. A., Vargas-Calderón, V., & Vinck-Posada, H. (2021). Classification with quantum measurements. Journal of the Physical Society of Japan, 90(4), 044002. <https://doi.org/10.7566/JPSJ.90.044002>

[13] González, F. A., Gallego, A., Toledo-Cortés, S., & Vargas-Calderón, V. (2024). Learning with density matrices and random features. Quantum Machine Intelligence, 6, 41. <https://doi.org/10.1007/s42484-024-00164-1>

[14] Gallego-Mejía, J. A., & González, F. A. (2023). DEMANDE: Density matrix neural density estimation. IEEE Access, 11, 53062–53078. <https://doi.org/10.1109/ACCESS.2023.3279123>

20. Reporte de originalidad: reporte creado por una herramienta de evaluación de la originalidad en la producción y en el manejo documental, a la cual se haya sometido el documento de Proyecto. Este reporte debe contar con el aval del director propuesto.

21. Consideraciones éticas: No

22. Posibles riesgos: Ninguno

23. ¿El proyecto requiere aval del Comité de Ética en la Investigación?
(SI___ NO_X_).



24. Firma del proponente:

#019268102

25. Firma del director propuesto:

Fabio A.
González

Digitally signed by
Fabio A. González
Date: 2025.12.12
11:43:07 -05'00'

26. Firma del Codirector propuesto (opcional): N/A

27. Fecha: 12/12/2025.